

我们做**随机实验**(random trial), 记为 E , 把实验的所有结果的集合叫作**样本空间**(sample sapce), 记为 Ω 。

随机事件(random event)是样本空间的子集, 简单称为**事件**。

频率 P

那么, 我们假设在同一条件下进行了 n 次实验, 再假设随机事件 A 在实验中发生了 k 次, 那么就事件的**频率**为:

$$f_n(A) = \frac{k}{n}$$

当 n 很大的时候, 频率 $\frac{k}{n}$ 趋于某一数值 p , 则称 p 为事件 A 发生的**概率**, 记为:

$$P(A) = p$$

公理化的定义是说, $P(A)$ 满足以下公理:

- 非负性: $P(A) \geq 0$
- 规范性: $P(\Omega) = 1$
- 可数可加性: $P(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} P(A_n)$

条件概率 $P(A|B) = \frac{P(AB)}{P(B)}$

我们说, 在事件 B 发生的前提下, 事件 A 发生的**条件概率**为:

$$P(A|B) = \frac{P(AB)}{P(B)}$$

条件概率 $P(A|B)$ 满足以下公理:

- 对任一事件 A , 有 $P(A|B) \geq 0$
- $P(\Omega|B) = 1$
- $P(\cup_{i=1}^{\infty} A_i|B) = \sum_{i=1}^{\infty} P(A_i|B)$

另外, **乘法公式**是说, 当 $P(B) > 0$ 时, 则有:

$$P(AB) = P(B)P(A|B)$$

全概率公式 $P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$

我们定义 A_1, A_2, \dots, A_n 为样本空间 Ω 的一个**划分**, 它满足:

- 划分中的任两个事件之间不相容
- 划分中的所有事件的总和构成样本空间

那么, 这里我们认定事件 B 为样本空间 Ω 中的任意事件, 因为 $P(B\Omega) = P(B) * P(\Omega) = P(B) * 1 = P(B)$

，所以这里给出公式推理：

$$\begin{aligned}P(B) &= P(B\Omega) = P(B(A_1 \cup A_2 \cup \cdots \cup A_n)) \\&= P(BA_1 \cup BA_2 \cup \cdots \cup BA_n) \\&= P(BA_1) + P(BA_2) + \cdots + P(BA_n) \\&= P(A_1)P(B|A_1) + P(A_2)P(B|A_2) + \cdots + P(A_n)P(B|A_n)\end{aligned}$$

贝叶斯公式 $P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^n P(B|A_j)P(A_j)}$

贝叶斯公式由条件概率和全概率公式组合而来，推理如下：

$$\begin{aligned}P(A_i|B) &= \frac{P(A_i B)}{P(B)} = \frac{P(BA_i)}{P(B)} \\&= \frac{P(B|A_i)P(A_i)}{P(B)} \\&= \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^n P(B|A_j)P(A_j)}\end{aligned}$$

一般来说，我们将划分 A_1, A_2, \dots, A_n 作为已知的结果，是说我们通过实验或者以往的信息经验之类的得到了 $P(A_j)$ 的值，所以我们称 $P(A_j)$ 为**先验概率**。此外，我们称 $P(A_i|B)$ 为**后验概率**，因为 $P(A_i|B)$ 是说在事件 B 发生后， A_i 再发生的概率。

通俗来说，就是我们通过了那么多的事件 A_1, A_2, \dots, A_n 得到了结果，也就是事件 B 的概率，但是我们还想要知道这个结果，也就是事件 B 发生的情况下，某个 A_j 发生的概率是多少这样。

分布函数 $F(x) = P\{X \leq x\}$

我们这里给出一个函数为：

$$X = X(A)$$

这里，我们把样本空间 Ω 中的每一个结果，或者说每一个事件都放入函数里，得到一个实数，比如 $X_1 = X(A_1), X_2 = X(A_2), \dots, X_n = X(A_n)$ 。

这样做的好处是，我们将一些实验的结果用数字进行替代，比如，我们要在一个装有红、绿、蓝小球的箱子里摸球，我们可以用数字来替代红、绿、蓝的结果， $X(\text{红}) = 1, X(\text{绿}) = 2, X(\text{蓝}) = 3$ 。

因为我们的函数 X 的值会随着实验的不同结果而变化，所以我们称 X 函数为**随机变量(random variable)**。

当然，我们一般用区间对 X 的值进行描述，因为有时候不能将每一个值都列出来，所以我们会说随机变量 X 的取值落在区间 $(x_1, x_2]$ 的概率，就是要求 $P\{x_1 \leq X \leq x_2\}$ 的值。

求 $P\{x_1 \leq X \leq x_2\}$ 的值就相当于要计算 $P\{X \leq x_2\} - P\{X \leq x_1\}$ 的值，那么就很容易知道我们其实是要研究 $P\{X \leq x\}$ 的概率问题了。因为它的值也是随着不同的 x 而变化的，所以我们叫 $P\{X \leq x\}$ 为 $P\{X \leq x\}$ ，这里给出它的公式：

$$F(x) = P\{X \leq x\}$$

分布函数有以下特点：

- $F(x_2) - F(x_1) = P\{x_1 < X \leq x_2\} > 0$
- $0 \leq F(x) \leq 1$

我们在这里对随机变量有个区分：

- 离散型随机变量：随机变量的取值为有限个或者可数无穷多个
- 连续型随机变量：随机变量的取值连续地充满某个区间

离散型随机变量-两点分布 $X \sim (0-1)$

当随机变量 X 的取值只有 x_1 和 x_2 这两个结果时，它的分布为：

$$\begin{aligned} P\{X = x_1\} &= p, \\ P\{X = x_2\} &= 1 - p, \quad 0 < p < 1 \end{aligned}$$

我们称 X 服从参数为 p 的**两点分布**，也叫 (0-1) 分布，记作 $X \sim (0-1)$ 。

离散型随机变量-二项分布 $X \sim b(n, p)$

当随机变量 X 的分布满足：

$$P\{X = k\} = C_n^k p^k (1-p)^{n-k}$$

则称 X 为服从参数为 n, p 的**二项分布(binomial distribution)**，记作 $X \sim b(n, p)$ 。

一般我们会使用 **泊松(Poisson)定理** 来进行近似计算，这里做个简单介绍。

设 $np_n = \lambda$ ，对任意非负整数有：

$$\lim_{n \rightarrow \infty} C_n^k p_n^k (1-p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

离散型随机变量-泊松分布 $X \sim P(\lambda)$

当随机变量 X 的分布满足：

$$P\{X = k\} = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots,$$

则称 X 为服从参数为 λ 的泊松分布(poisson distribution)，记作 $X \sim P(\lambda)$ ，其中 λ 为常数。

概率密度函数 $f(x)$

这里介绍一个概念，**概率密度函数(density function)**。它可以用来描述随机变量 X 的分布函数 $F(x)$ ：

$$F(x) = \int_{-\infty}^x f(t) dx$$

它有以下特点：

- $f(x) \geq 0$
- $\int_{-\infty}^{+\infty} f(x)dx = 1$
- $P\{x_1 < X < x_2\} = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(t)dx$

连续型随机变量-均匀分布 $X \sim U(a, b)$

当随机变量 X 具有概率密度：

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{其他} . \end{cases}$$

则称 X 在区间 (a, b) 上服从**均匀分布(uniform distribution)**, 记作 $X \sim U(a, b)$

积分求得 X 的分布函数：

$$F(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x < b, \\ 1, & x \geq b. \end{cases}$$

连续型随机变量-指数分布 $X \sim E(\lambda)$

当随机变量 X 具有概率密度：

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

则称 X 服从 λ 的**指数分布(exponential distribution)**, 记作 $X \sim E(\lambda)$, 其中 λ 为常数。

积分求得 X 的分布函数：

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

连续型随机变量-正态分布 $X \sim N(\mu, \sigma^2)$

当随机变量 X 具有概率密度：

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < +\infty$$

则称 X 服从参数为 μ, σ 的**正态分布(normal distribution)**, 记作 $X \sim N(\mu, \sigma^2)$, 其中 μ 和 $\sigma(\sigma > 0)$ 为常数。

积分求得 X 的分布函数：

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$

特别的, 当 $\mu = 0, \sigma = 1$ 时, 我们称 X 服从标准正态分布 $N(0, 1)$, 这时它的概率密度表示为:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2}}$$

分布函数表示为:

$$\phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

一般地, 若 $X \sim N(\mu, \sigma^2)$, 那么 $\frac{X-\mu}{\sigma} \sim N(0, 1)$, 我们可以通过正态函数表来计算正态分布:

$$\begin{aligned} P\{\mu - \sigma < X < \mu + \sigma\} &= \phi(1) - \phi(-1) = 2\phi(1) - 1 = 0.6826 \\ P\{\mu - 2\sigma < X < \mu + 2\sigma\} &= \phi(2) - \phi(-2) = 2\phi(2) - 1 = 0.9544 \\ P\{\mu - 3\sigma < X < \mu + 3\sigma\} &= \phi(3) - \phi(-3) = 2\phi(3) - 1 = 0.9974 \end{aligned}$$

联合分布函数 $F(x, y) = P\{X \leq x, Y \leq y\}$

在这里, 我们考虑两个随机变量 $X(e)$ 和 $Y(e)$ 的组合。我们把 $(X(e), Y(e))$ 称为**二维随机向量(2-dimensional random vector)**, 简单记作 (X, Y) 。

显然, 我们可以得到二维随机向量 (X, Y) 的分布函数, 或者说, 随机变量 X 和随机变量 Y 的**联合分布函数**:

$$F(x, y) = P\{X \leq x, Y \leq y\}$$

边缘分布函数 $F_X(x), F_Y(y)$

我们说到联合分布函数是二维随机变量 (X, Y) 的分布函数, 自然随机变量 X 和 Y 是有分布函数的, 那么我们通过联合分布函数来求得变量 X 和 Y 的分布函数, 就可以得二维随机变量 (X, Y) 关于 X 和 Y 的边缘分布函数 (marginal distribution function):

$$\begin{aligned} F_X(x) &= P\{X \leq x\} = P\{X \leq x, Y < +\infty\} = F(x, +\infty) \\ F_Y(y) &= P\{Y \leq y\} = P\{X < +\infty, Y \leq y\} = F(+\infty, y) \end{aligned}$$

数学期望 $E(X)$

我们现在知道一个离散型变量 X 的分布律为:

$$P\{X = x_k\} = p_k, k = 1, 2, \dots$$

如果满足条件 $\sum_{k=1}^{\infty} x_k p_k$ 绝对收敛, 那么有**数学期望(mathematical expectation)**, 记作 $E(X)$, 即:

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

当然, 如果是一个连续型的随机变量 X 的话, 我们就假设它有概率密度函数 $f(x)$ 。

如果满足积分 $\int_{-\infty}^{+\infty} x f(x) dx$ 绝对收敛, 那么同样有数学期望为:

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

数学期望有一些性质：

- $E(c) = c$, 其中 c 为常数;
- $E(cX) = cE(X)$;
- $E(X + Y) = E(X) + E(Y)$;
- $E(XY) = E(X)E(Y)$, 其中 X, Y 相互独立。

	(0 - 1)分布	二项分布	泊松分布	均匀分布	指数分布	正态分布
$E(X)$	p	np	λ	$\frac{a+b}{2}$	$\frac{1}{\lambda}$	μ

方差 $D(X)$

数学期望描述了随机变量取值的“平均数”，而**方差(variance)**是用来度量随机变量取值的分散程度的，记作 $D(X)$ ，即：

$$D(X) = E[X - E(X)]^2 = E(X^2) - [E(X)]^2$$

其中，我们称 $\sqrt{D(X)}$ 为随机变量 X 的**标准差(standard deviation)**，或**均方差(mean square deviation)**，记作 $\sigma(X)$ 。

方差有一些性质：

- $D(c) = 0$, 其中 c 为常数;
- $D(cX) = c^2 D(X)$;
- $D(X \pm Y) = D(X) + D(Y) \pm 2E[(X - E(X))(Y - E(Y))]$;
- $D(X \pm Y) = D(X) + D(Y)$, 其中 X, Y 相互独立。

	(0 - 1)分布	二项分布	泊松分布	均匀分布	指数分布	正态分布
$D(X)$	$p(1 - p)$	$np(1 - p)$	λ	$\frac{(a+b)^2}{12}$	$\frac{1}{\lambda^2}$	σ^2

协方差 $cov(X, Y)$

数学期望和方差反映的都是随机变量自身的内容，这里我们考虑随机变量相互之间的影响，一般会使用**协方差(covariance)**来描述，即：

$$cov(X, Y) = E\{[X - E(X)][Y - E(Y)]\}$$

其中，我们称 $\frac{cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$ 为随机变量 X, Y 的**相关系数(correlation coefficient)**，或标准协方差(standard covariance)，记作 ρ_{XY} ，即：

$$\rho_{XY} = \frac{cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

一些实用的计算公式：

$$D(X \pm Y) = D(X) + D(Y) \pm 2cov(X, Y)$$

$$cov(X, Y) = E(XY) - E(X)E(Y)$$